

# Detección del SIT utilizando un vehículo aéreo no tripulado

Le agradecemos a la docente Rosa Yuliana Paccotacya Yanque por su guía en el curso de Robotica de la Escuela Profesional de Ciencia de la Computación

1<sup>st</sup> Vizcarra Vargas, Piero

*Ciencia de la Computación*

*Universidad Nacional de Ciencia de la Computación*

Arequipa , Peru

pvizcarra@unsa.edu.pe

2<sup>nd</sup> Huanca Parqui, Elizabeth Yasmin

*Ciencia de la Computación*

*Universidad Nacional de Ciencia de la Computación*

Arequipa , Peru

pvizcarra@unsa.edu.pe

3<sup>rd</sup> Palli Livisi, Eden

*Ciencia de la Computación*

*Universidad Nacional de Ciencia de la Computación*

Arequipa , Peru

pvizcarra@unsa.edu.pe

4<sup>th</sup> Mamani Quispe Alex Enrique

*Ciencia de la computación.*

*Universidad Nacional de San Agustín de Arequipa*

Arequipa, Arequipa

amamaniq@unsa.edu.pe

5<sup>th</sup> Macedo Huaman Vanessa Mayra

*Ciencia de la computación.*

*Universidad Nacional de San Agustín de Arequipa*

Arequipa, Arequipa

vmacedoh@unsa.edu.pe

**Abstract**—This project proposes to detect the public transport activity of the SIT with the aim of improving the quality of currently existing transport systems, which will be an important initiative for the search for solutions for urban and modern structures, the key points here are the urban efficiency and mobility, security and control, sustainable urban planning and the best user experience, optimal and optimization of resources.

The problem here is that the context focuses on the lack of efficient systems for tracking and managing public transport vehicles in real time. The absence of accurate and up-to-date information that could cause inconvenience to users increases the risk of safety and difficult decisions made by the transportation and urban planning authority.

**Index Terms**—Urban efficiency , Sustainable urban planning, Real-time tracking, Transportation authority, Public transport activity, User experience

## I. INTRODUCCIÓN

En este proyecto se propone detectar la actividad del transporte público del SIT con el objetivo de mejorar la calidad de los sistemas de transporte actualmente existentes, que será una importante iniciativa para la búsqueda de soluciones para estructuras urbanas y modernas, los puntos clave aquí son la eficiencia y movilidad urbana, la seguridad y el control, la planificación urbana sostenible y la mejor experiencia de usuario, óptima y optimización de los recursos. El problema aquí es que el contexto se centra en la falta de sistemas

Le agradecemos a la docente Rosa Yuliana Paccotacya Yanque por su guía en el curso de Robotica de la Escuela Profesional de Ciencia de la Computación

eficientes de seguimiento y gestión de los vehículos del transporte público en tiempo real. La ausencia de información precisa y actualizada que pueda generar inconvenientes a los usuarios aumenta el riesgo de seguridad y decisiones difíciles tomadas por la autoridad de transporte y planificación urbana.

## II. METODOLOGÍA

Se utiliza transfer learning para obtener el modelo ideal, para el entrenamiento del modelo se están utilizando 180 imágenes, se utiliza una partición de 70 -30 para poder usarlo, se compara la diferencia en el entrenamiento total para el aprendizaje del sistema, y como se muestra en los gráficos, para cada uno hay un dato diferente, porque hay dos técnicas distintas, y lo que no sirve es la temática del set, por ejemplo, en el entrenamiento total, si entrenar un modelo de cero en lugar de la transferencia de datos de otro modelo, como la técnica de transferencia de aprendizaje, muestra que tiene un 82% de precisión, y además si usamos la técnica de transferencia de aprendizaje, estamos usando un modelo pre-entrenado. , y pasar datos concretos a ver si nos da una mejora del 88%, aunque parece poco ver los datos juntos, y es significativo, y lo que podemos ver aquí en la siguiente, aquí estamos haciendo los datos completos En los resultados entregado se muestra una interfaz para que el modelo vea como detecta la mayor cantidad de imágenes y como podemos ver que los resultados son que detecta los modelos del sitio al 98% cuales son los autos de un T3, un T8 y que nos da una buena ventaja porque el problema mencionado es mejorar la

calidad del transporte público. En este primer paso es detectar el transporte y ver si coincide exactamente con las rutas que proporciona el personal afín y el sitio, así se consigue mejorar la eficiencia del transporte en Arequipa pues muchas veces se presentan fallos en el sistema SIT debido a que hay muchos reparamientos o incluso ahora con la liberación que fue en el año 2023 que hubo problemas con la falta de abastecimiento de unidades entonces para mejorar a futuro el sistema integral de transporte el objetivo es tener un conjunto de datos y a partir de este entrenamiento poder utilizarlo en más imágenes y más entornos por lo cual nosotros vamos a ver si es que la unidad, las unidades de transporte están ejecutando correctamente su ruta en los momentos adecuados.

### III. FUNDAMENTOS DE VISIÓN POR COMPUTADORA Y APRENDIZAJE AUTOMÁTICO

#### A. Visión por Computadora

La visión por computadora es una rama de la inteligencia artificial que permite a las máquinas interpretar y tomar decisiones basadas en información visual. Según Szeliski (2010) [?], esta disciplina abarca una variedad de tareas como la detección y reconocimiento de objetos, la cual es fundamental para la identificación de vehículos y peatones en imágenes capturadas por drones.

#### B. Aprendizaje Automático y Profundo

El aprendizaje automático es el corazón del análisis moderno de imágenes, proporcionando herramientas para el reconocimiento de patrones y la toma de decisiones. Goodfellow et al. (2016) [?] destacan cómo las redes neuronales profundas han revolucionado la capacidad de las máquinas para interpretar imágenes complejas, una técnica crucial para nuestro sistema de detección.

#### C. Detección de Objetos y Técnicas Relevante

La detección de objetos es un desafío clave en la visión por computadora. Métodos como R-CNN Girshick et al., 2014 [?] y YOLO Redmon et al., 2016 [?] han demostrado ser efectivos en la localización y clasificación de objetos en tiempo real. Estos enfoques son particularmente pertinentes para el seguimiento de vehículos en movimiento desde drones.

#### D. Aprendizaje por Transferencia

El aprendizaje por transferencia involucra la adaptación de modelos pre-entrenados a nuevos contextos. Zoph et al. (2018) [?] demuestran cómo las arquitecturas transferibles pueden mejorar significativamente la eficiencia del entrenamiento y la precisión en tareas de visión por computadora, una estrategia que implementamos para acelerar el desarrollo de nuestro modelo.

### IV. EXPERIMENTOS

#### A. Configuración del Entorno

Iniciamos asegurando la disponibilidad de recursos de GPU para el procesamiento de imágenes y detección de objetos, verificando el estado de NVIDIA con el comando `!nvidia-smi`.

#### B. Instalación de Dependencias

Se instaló la versión 8.0.20 de la biblioteca *ultralytics* usando pip. Esta biblioteca es crucial para emplear el algoritmo YOLO, ampliamente utilizado en tareas de detección de objetos.

#### C. Preparación del Modelo YOLO

Importamos las funciones necesarias de *ultralytics* y preparamos el modelo YOLO para la detección de objetos. Utilizamos métodos específicos para verificar la configuración y asegurar la correcta ejecución de las tareas de detección.

#### D. Descripción del Experimento

Este experimento se centra en detectar la actividad del transporte público del SIT. Utilizamos aprendizaje por transferencia para obtener un modelo ideal, entrenándolo con 180 imágenes y utilizando una partición 70-30 para el conjunto de datos. Comparamos la eficacia de entrenar desde cero frente a utilizar un modelo pre-entrenado.

#### E. Resultados

Los resultados muestran que la detección de vehículos del SIT alcanza una precisión del 98% para modelos específicos como T3 y T8. Se presentan también interfaces para visualizar cómo el modelo detecta imágenes en tiempo real. Estos resultados son significativos para mejorar la eficiencia del transporte en Arequipa, especialmente en el contexto de problemas recientes de abastecimiento de unidades.

Los experimentos condujeron a la obtención de dos matrices de confusión, que reflejan la capacidad del modelo para clasificar correctamente entre las diferentes categorías: SIT, car, person, police, y background.

#### F. Matriz de Confusión del Primer Modelo

La Figura 1 muestra la matriz de confusión para el primer modelo. Los elementos diagonales representan las tasas de clasificación correcta para cada clase, siendo notable la alta precisión para las clases SIT y background. Sin embargo, la clase car muestra una mayor confusión con la clase SIT, lo que indica un área de mejora.



Fig. 1. Matriz de confusión del primer modelo.

### G. Matriz de Confusión del Segundo Modelo

En la Figura 3, la matriz de confusión del segundo modelo exhibe una mejora significativa en la distinción entre las clases car y SIT, reduciendo la tasa de falsos positivos y aumentando la precisión general del modelo.




Fig. 2. Matriz de confusión del segundo modelo.

La discusión de estos resultados sugiere que el segundo modelo proporciona una discriminación más clara entre las categorías de interés, lo cual es esencial para la aplicación práctica en la detección de vehículos y la gestión del tráfico del SIT.

### H. Discusión

En base a nuestro experimento tenemos resultado a que el Modelo 1 y 2 el modelo 2 implementado con Transfer Learning nos da un mejor detección de los transportistas del SIT.

Podemos ver nuestro test de validación para poder verificar su correcto funcionamiento del modelo de Yolo y el de Transfer Learning.



Fig. 3. Imagen de Validación

### V. CONCLUSIONES

- El modelo mejorado demuestra una capacidad significativamente aumentada para distinguir entre las clases SIT y car, indicando una optimización efectiva del algoritmo de clasificación.
- La detección de la clase background mantiene una alta precisión en ambos modelos, sugiriendo una robusta habilidad del modelo para identificar contextos sin objetos relevantes.
- A pesar de las mejoras observadas, persiste cierta confusión con la clase person, resaltando una oportunidad para el refinamiento en futuras iteraciones de entrenamiento.
- El rendimiento del modelo final es prometedor para su aplicación práctica en la mejora de la gestión del tráfico y la eficiencia del transporte público en el sistema SIT de Arequipa.
- Los resultados enfatizan la importancia de continuar el desarrollo de técnicas de aprendizaje por transferencia y ajuste fino, especialmente adaptadas a las complejidades del ambiente urbano y de transporte.
- Se aconseja la realización de mejoras adicionales y pruebas exhaustivas para asegurar la confiabilidad y solidez del sistema en variadas condiciones y horarios.
- La cooperación con las autoridades de transporte y urbanismo es crucial para una implementación exitosa y para obtener retroalimentación que permita calibrar el modelo según las necesidades reales del sistema de transporte.
- Es imperativo recolectar más datos para incrementar la precisión del modelo, particularmente para las clases con menor rendimiento, y para preparar el sistema para adaptarse a futuros cambios en el SIT.

### REFERENCIAS

#### REFERENCES

- [1] G. Eason, B. Noble, and I. N. Sneddon, "On certain integrals of Lipschitz-Hankel type involving products of Bessel functions," Phil. Trans. Roy. Soc. London, vol. A247, pp. 529–551, April 1955.
- [2] J. Clerk Maxwell, A Treatise on Electricity and Magnetism, 3rd ed., vol. 2. Oxford: Clarendon, 1892, pp.68–73.
- [3] I. S. Jacobs and C. P. Bean, "Fine particles, thin films and exchange anisotropy," in Magnetism, vol. III, G. T. Rado and H. Suhl, Eds. New York: Academic, 1963, pp. 271–350.
- [4] K. Elissa, "Title of paper if known," unpublished.
- [5] R. Nicole, "Title of paper with only first word capitalized," J. Name Stand. Abbrev., in press.
- [6] Y. Yorozu, M. Hirano, K. Oka, and Y. Tagawa, "Electron spectroscopy studies on magneto-optical media and plastic substrate interface," IEEE Transl. J. Magn. Japan, vol. 2, pp. 740–741, August 1987 [Digests 9th Annual Conf. Magnetism Japan, p. 301, 1982].
- [7] M. Young, The Technical Writer's Handbook. Mill Valley, CA: University Science, 1989.
- [8] J. Redmon et al. "You Only Look Once: Unified, Real-Time Object Detection." En Proceedings of the IEEE conference on computer vision and pattern recognition, 2016.